KWEDTH: 한국형 산불 조기예측 AI 모델 개발

김은기

2025년 10월 17일

목차

1. 프로젝트 목표
2. 1-2차 모델 개발
3. 한국형 산불 조기예측 AI 모델 개발
4. 산불 예측 시스템 구현 작업
5. 결론 및 제언

Ⅰ. 프로젝트 목표

본 프로젝트의 목표는 **한국 지역에 특화된 실시간 조기 예측 AI 모델 (KWETH)**를 개발하여, 위성 관측 데이터를 기반으로 소방 대응 지원 NASA FIRMS 및 일본 Himawari 위성 데이터를 활용하여 실시간 화재 탐지 및 확산 예측 모델 개발 시스템 구축

(1) 초기 목표

- Flame(fire) 객체의 **Recall 0.6 이상**을 달성하는 것이 1차 목표
- Roboflow 및 FASDD 데이터셋을 활용한 YOLO 기반 탐지모델(YOLOv8m, YOLO11)로 화염 및 연기 탐지를 시도.

(2) 문제 인식

- 앞선 모델들이 화염·연기의 형태 기반 탐지에 초점을 두었다면,
  본 단계에서는 **열적 패턴(thermal signature)** 을 직접 활용해 조기 탐지 정확도를 높이는 것을 목표
- NASA 아쿠아 위성이 **산청 지역 화재 당시 연기를 포착했음에도 불구하고 조기대응이 실패**한 사례를 분석하면서,
  "형태 기반 탐지"만으로는 조기 예측에 한계가 있음을 인식

(3) 목표 재정의

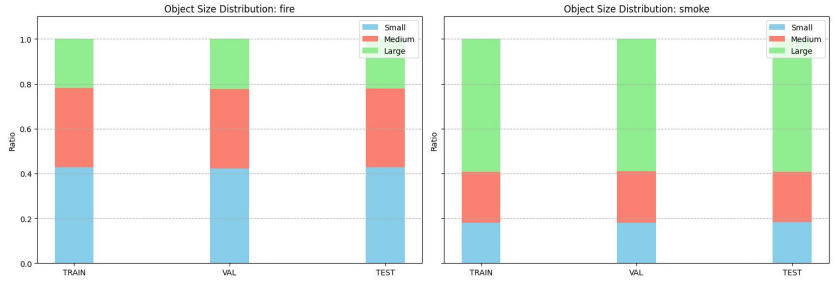
- 단순 시각적 탐지에서 벗어나, **열(적외선 밴드)** 정보 기반의 화재 패턴 학습 모델로 확장하기로 함.
- 새로운 가정: "온도 차이를 학습한 AI가 다음 산불 발생 지점을 예측할 수 있다."
- 이에 따라 **최종 개발 목표**를 다음과 같이 재정의
- 개발 목표: 한국 산불 화재 조기 탐지 더 헬퍼 (KWEDTH)
- 개발 정의**:** 산불의 **화재 패턴(열 + 모양)** 을 학습한 AI 모델(KWEDTH)이 픽셀 단위 핫스팟(임계치 초과 열점)을 예측하도록 하는 목적에 맞추어 **segment 기반 모델**을 채택함.

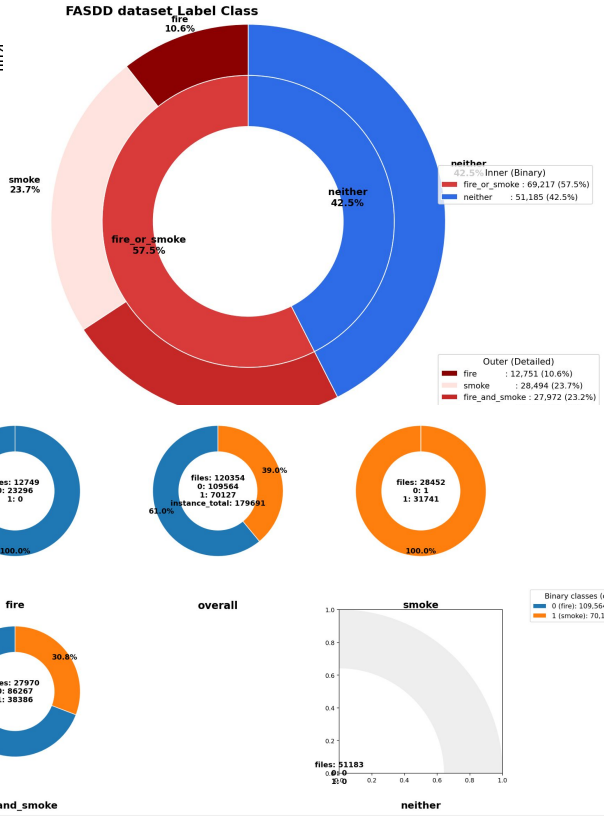
Ⅱ. 1차 모델 데이터셋

- 라벨(coco json) 분석 결과 fire or smoke (57.5%)로 첫번째 데이터셋에 비해
- 화염이 잘 확보된 데이터이며 네거티브 이미지(n=3,473)를 학습시켜 과적합 줄
- 일괄 리사이즈(640)/레터박스 전처리/라벨과 이미지 매칭 여부 전처리
- copy & paste 증강기법으로 작은 크기 smoke가 적은 문제를 해결 (+fire도)
- 최종 데이터셋은 train(n=76,645), val(n=18,272), test(=15,891) 균형 확보



Final Dataset Balance Check (Class x Object Size)

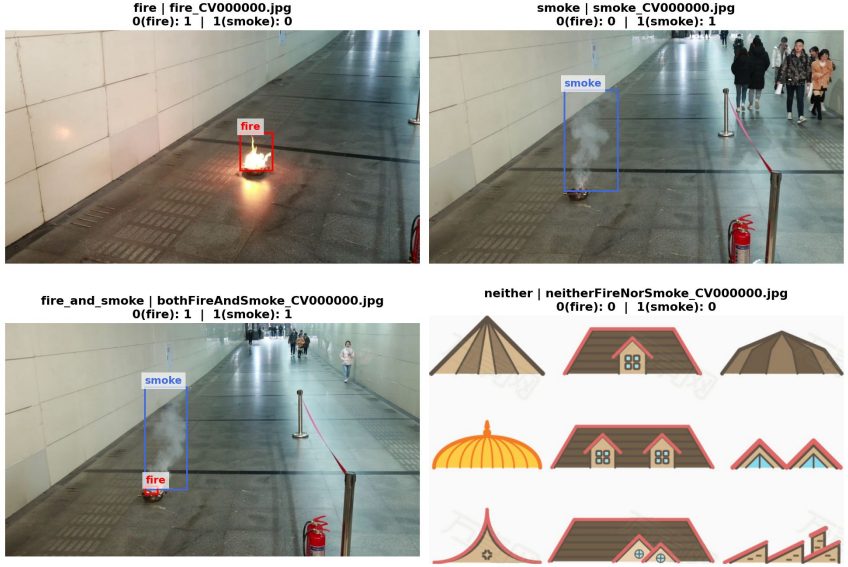




Ⅱ. 1차 모델 라벨

- COPY & PASTE 증강 이후 Bounding-box 라벨이 유효한 것에 한해 COCO- JSON 형식을 yolo.txt로 라벨로 변환
- data.yaml 작성 시 클래스는 [FIRE-0, SMOKE=1], negative image는 빈 txt로 보존 (일반화 목적)

< 라벨링 결과>



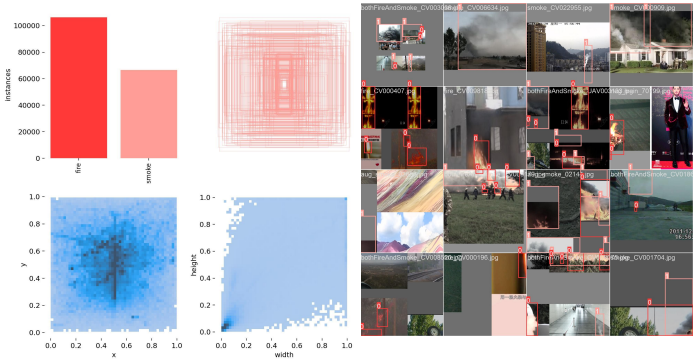
< B-BOX 유효성 결과>

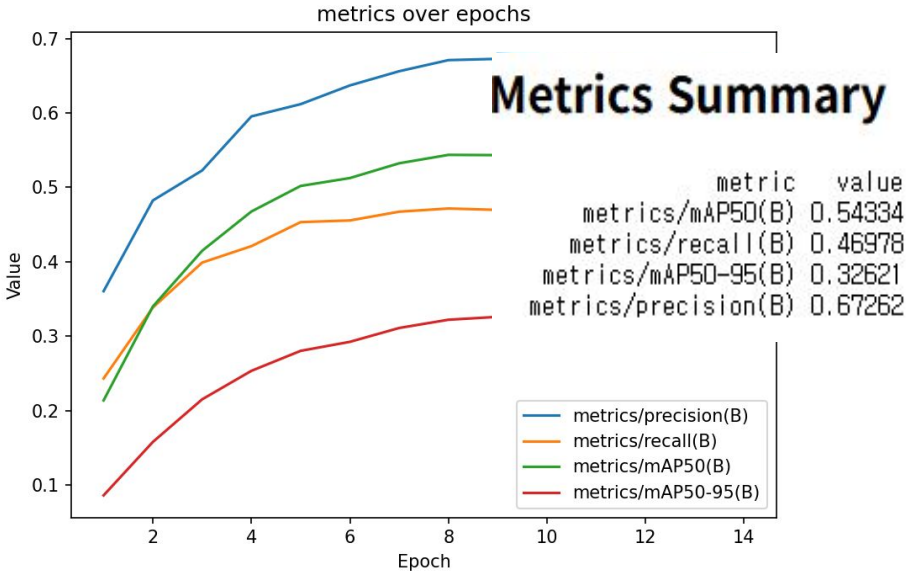


Ⅱ. 1차 모델링

- 스모크 테스트 이후 yolo8s로 훈련 진행
- yolo8s는 precision이 0.67으로 높았으나, recall과 map50이 상대적으로 낮았음
- 학습데이터가 다양한 상황을 반영함에 따라 재현율은 다소 낮은 것으로 보임
- 다만, fire이 smoke 보다 수가 많다는 장점이 있으며, 정교하게 훈련이 진행됨
- lr0: 0.01, optimizer: AdamW 사용, 시간 관계상 10에포크 전에 중단함

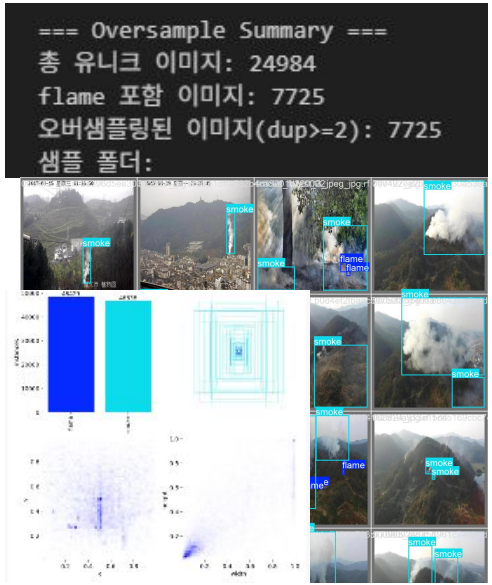
```
Total original train images: 76645
Smoke train images (5%): 15329
Total original val images: 18272
Smoke val images (5%): 3654
```

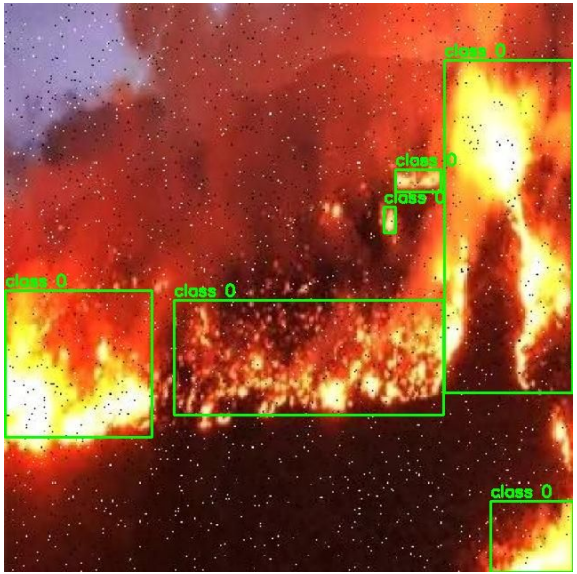




Ⅱ. 2차 모델 데이터셋 & 라벨

- 작은 사이즈 화염 문제 - > flame over-sampling 7,725개로 화염과 스모크의 균형 확보하였다는 장점
- counts per split: {'train': Counter({1: 29646, 0: 16143}), 'valid': Counter({1: 2581, 0: 983})}
- roboflow에서 그대로 data.yaml을 받아오는 경우 라벨링이 전부 '-'로 표시되는 문제가 있었으나 yaml 수정
- val.batch에서 밝은 불빛을 화염으로 인식하는 문제를 발견함함



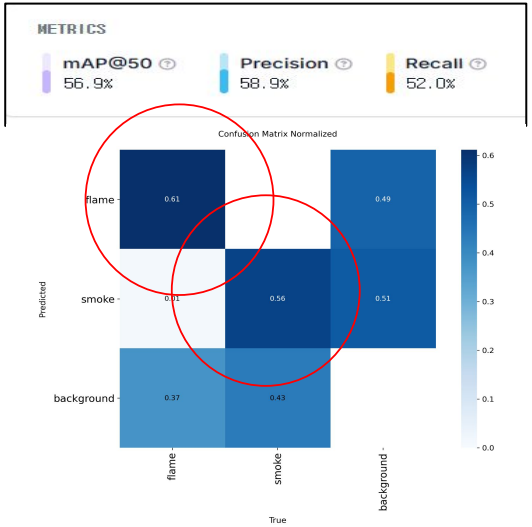




Ⅱ. 2차 모델링

- Roboflow 설명값보다 Precision 0.619(+0.03%p), Recall 0.524(+0.4%p), mAP@50 0.591(+ 0.022%p)까지 향상
- Recall은 flame =0.44/smoke=0.607로 화염의 Recall값이 상대적으로 낮음
- Backbone을 freeze/unfreeze 하는 경우 Precision 0.639까지 향상되나, Recall값은 오히려 감소하는 경향
- conf sweep 하는 경우 Precision은 감소하지만, Recall값은 높아짐 (fire=0.539, smoke=0.502 => fire 0.6에 근접)
- confusion metrix 결과, fire TP=0.61, smoke TP =0.56

<roboflow metrics>



<my model metrics>

Class	Images	Instances	Box(P	R	mAP50	mAP50-95):
all	90	309	0.619	0.524	0.591	0.291
flame	77	225	0.572	0.44	0.494	0.229
smoke	70	84	0.666	0.607	0.689	0.353

< my model backbone freeze/unfreeze metrics>

label	phase	metrics/recall(B)	metrics/mAP50(B)	metrics/mAP50-95(B)
unfreeze	freeze	0.451	0.533	0.302
freeze	freeze	0.466	0.515	0.280
origin	origin	0.256	0.204	0.084

< my model conf sweep metrics>

Class	Images	Instances	Box(P	R	mAP50	mAP50-95):
all	1791	3564	0.586	0.521	0.552	0.316
flame	602	983	0.459	0.539	0.466	0.241
smoke	1703	2581	0.714	0.502	0.639	0.39

Ⅱ. 2차 모델 예측 결과

- 스트리밍 영상 (crop한 결과)의 불꽃을 잘 감지하며, 열화상 이미지도 감지하는 것을 확인



Ⅲ. 한국형 산불 조기예측 AI 모델 개발

(3) 3차 모델: 한국 지역 위성 기반 조기 탐지 (NASA + Himawari)

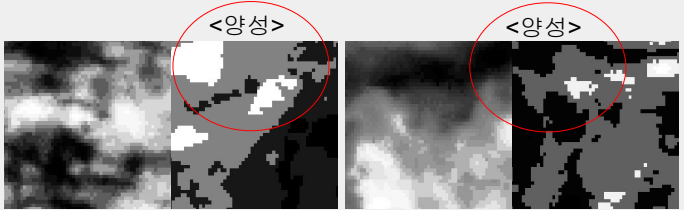
- 앞선 모델들이 화염·연기의 형태 기반 탐지에 초점을 두었다면, 본 단계에서는 **열적 패턴(thermal signature)** 을 직접 활용해 조기 탐지 정확도를 높이는 것을 목표
- **배경**: 2025년 3월, NASA 위성이 한반도 연기를 포착했음에도 산불 조기탐지 실패 사례 발생
- **목표**: NASA FIRMS와 Himawari AHI 위성 데이터를 결합해 실시간 감지 모델 개발

주요 단계

1. **데이터 수집**
   - NASA FIRMS API 이용, 최근 3~5개월 한국지역 화재데이터 수집 (총 8,932건)
2. **문제 ①**: FIRMS 데이터 업로드 지연
3. 해결 → Himawari AHI 실시간 데이터(15분 단위, 122,340장) 사용, 이미지 샘플 수 4,326개
   - AWS S3 + SQS 기반 파이프라인 구성 → Kibana 대시보드로 실시간 시각화
4. **문제 ②**: 정확한 화재 위치 식별
   - FIRMS 좌표와 Himawari 화상 매핑 → **고유 슬롯(124)** 생성
   - FIRMS 좌표 기반 **mask label** 생성 후 fixel z-score로 정규화
     동일 크기 crop으로 **mask chip dataset** 구성 및 segmentation 모델 학습
   - 예측 결과에 **fire gate + RGB overlay** 적용하여 시각화



Ⅲ. 3차 모델 데이터셋 & 라벨링



- 10월 11일 : firms fire dataset과 himawari 8/9 ahi를 매핑하여 훈련 데이터(이미지)를 구성
- 2025년 3~5월 한국 대형 산불이 발생했던 지역 약 12곳의 피처 포함 데이터 총 9,582개, 실시간 이미지 122,340개 수집
- 유효한 시간대 슬롯 총 124개 수집 => b14(열적외선) 밴드를 통해 마스크를 생성함 총 4,326개
- b14 열적외선 밴드 유효 슬롯을 통해 양성과 음성칩 파일(tif 형식)을 생성함 (3,000x3,000)

	AOI	FIRMS rows	FIRMS date min	FIRMS date max	Himawari key rows	Unique time slots
0	.ipynb_checkpoints	0			0	0
1	Bonghwa	6	2025-03-25	2025-03-25	2560	4
2	Daegu-Buk_(Apr28–May1)	76	2025-04-28	2025-04-30	8320	13
3	Daegu_Buk_(Apr6)	0			0	0
4	Dalseong_(Daegu)	0			0	0
5	Gimhae	51	2025-03-22	2025-03-25	6400	10
6	Gochang–Jeongeup	4	2025-03-25	2025-03-25	1280	2
7	Hadong_(Apr7–8)	118	2025-04-07	2025-04-08	9600	15
8	Inje	9	2025-04-26	2025-04-26	1280	2
9	Muju	8	2025-03-26	2025-03-26	1920	3
10	Okcheon–Yeongdong	5	2025-03-23	2025-03-23	1280	2
11	Sancheong-Hadong	885	2025-03-21	2025-03-30	41600	65
12	Uiseong-Andong-Cluster	8392	2025-03-22	2025-03-30	46080	72
13	Ulju–Eonyang	28	2025-03-25	2025-03-25	5120	8
14	Ulju–Onyang	0			0	0
15	_backup_masks_20251011_144056	0			0	0
16	buffers	0			0	0
17	coco_timeslots_Bonghwa	0			0	0

[GeoJSON 요약] AOI 수: 17

AOI	features	unique_slots	first_date	last_date
Bonghwa	6	4	2025-03-25	2025-03-25
Daegu-Buk_(Apr28–May1)	76	13	2025-04-28	2025-04-30
Daegu-Buk_Apr28_May1	76	13	2025-04-28	2025-04-30
Gimhae	51	10	2025-03-22	2025-03-25
Gochang_Jeongeup	4	2	2025-03-25	2025-03-25
Gochang–Jeongeup	4	2	2025-03-25	2025-03-25
Hadong_(Apr7–8)	118	15	2025-04-07	2025-04-08
Hadong_Apr7_8	118	15	2025-04-07	2025-04-08
Inje	9	2	2025-04-26	2025-04-26
Muju	8	3	2025-03-26	2025-03-26
Okcheon_Yeongdong	5	2	2025-03-23	2025-03-23
Okcheon–Yeongdong	5	2	2025-03-23	2025-03-23
Sancheong-Hadong	885	66	2025-03-21	2025-03-30
Uiseong-Andong-Cluster	8392	72	2025-03-22	2025-03-30
Ulju_Eonyang	28	8	2025-03-25	2025-03-25
Ulju–Eonyang	28	8	2025-03-25	2025-03-25
all_aois_buffers	9582	124	2025-03-21	2025-04-30

[TIF 요약] 파일 수: 12
고유 CRS: ['EPSG:4326']
고유 크기(WxH): [(3000, 3000)]

AOI	width	height	crs	res_x	res_y	nonzero_px
Bonghwa	3000	3000	EPSG:4326	0.000021	0.000020	793776
Daegu-Buk_Apr28_May1	3000	3000	EPSG:4326	0.000073	0.000034	331736
Gimhae	3000	3000	EPSG:4326	0.000033	0.000085	622570
Gochang_Jeongeup	3000	3000	EPSG:4326	0.000021	0.000023	1084975
Hadong_Apr7_8	3000	3000	EPSG:4326	0.000065	0.000108	216469
Inje	3000	3000	EPSG:4326	0.000025	0.000023	1253443
Muju	3000	3000	EPSG:4326	0.000026	0.000023	1158339
Okcheon_Yeongdong	3000	3000	EPSG:4326	0.000018	0.000018	417357
Sancheong-Hadong	3000	3000	EPSG:4326	0.000204	0.000220	243406
Uiseong-Andong-Cluster	3000	3000	EPSG:4326	0.000455	0.000412	571416
Ulju_Eonyang	3000	3000	EPSG:4326	0.000027	0.000024	1443439
all_aois_buffers	3000	3000	EPSG:4326	0.000922	0.001048	133122

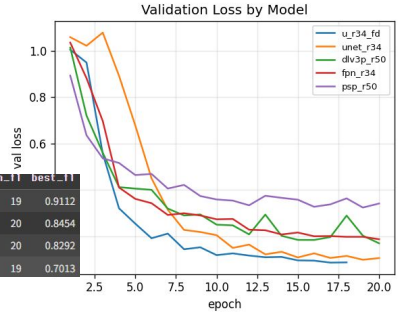
Ⅲ. 3차 모델링

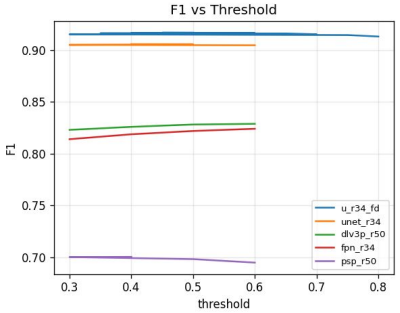
- third model framework architecture: (smp.Unet), encoder (restnet34)
- smoke test로 4가지 모델을 돌려보고 best 성능을 보인 Unet restnet34 + force, dice로 미세 튜닝
- 최종 모델은 F1 score=0.917, Precision=0.916, Recal=0.926로 성능이 가장 크게 개선

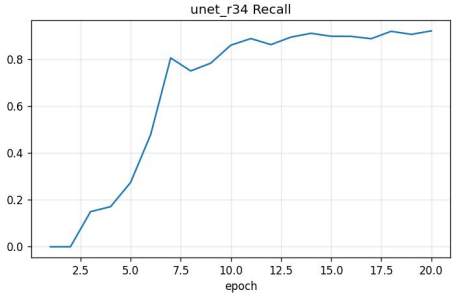
Leaderboard (best over thresholds)

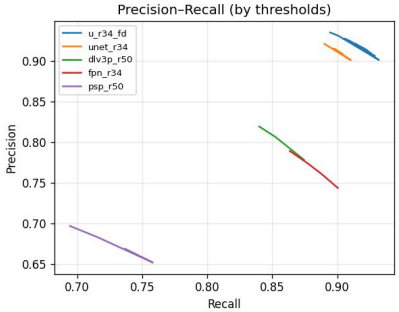
tag	best_thr	F1	IoU	Precision	Recall
u_r34_fd	0.50	0.917	0.849	0.916	0.920
unet_r34	0.40	0.906	0.828	0.908	0.904
dlv3p_r50	0.60	0.829	0.710	0.819	0.840
fpn_r34	0.60	0.824	0.702	0.789	0.864

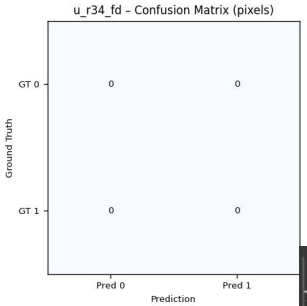
	tag	best_epoch_val	best_val	iou_at_best	f1_at_best	best_epoch_f1	best_f1
0	unet_r34	19	0.099196	0.8369	0.9112	19	0.9112
1	dlv3p_r50	20	0.170077	0.7325	0.8454	20	0.8454
2	fpn_r34	20	0.187660	0.7084	0.8292	20	0.8292
3	psp_r50	19	0.324302	0.5402	0.7013	19	0.7013

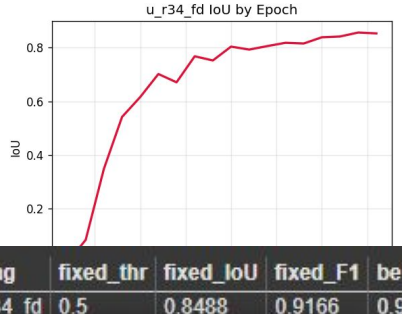


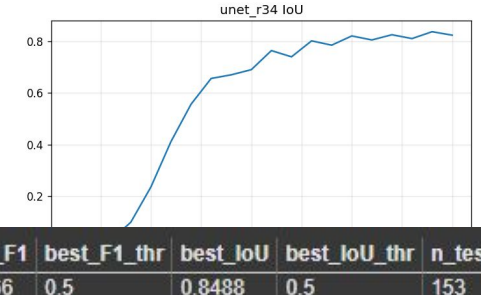








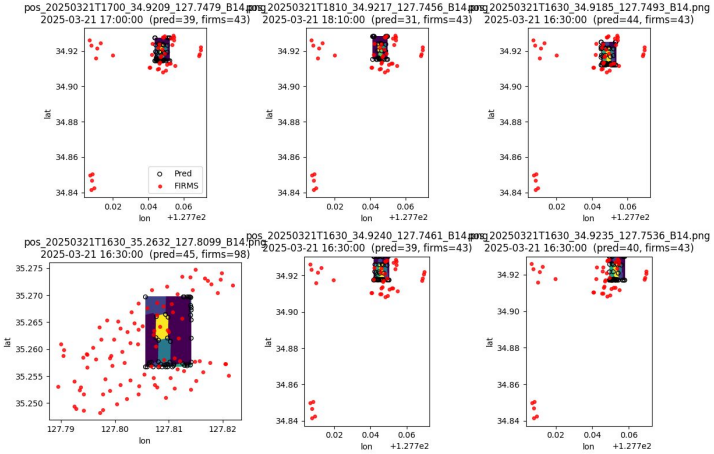




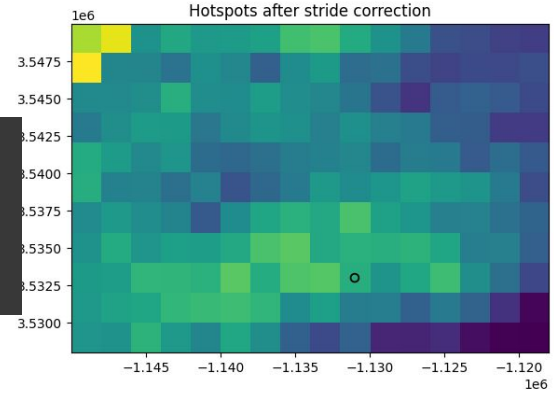
tag	fixed_thr	fixed_IoU	fixed_F1	best_F1	best_F1_thr	best_IoU	best_IoU_thr	n_test
u_r34_fd	0.5	0.8488	0.9166	0.9166	0.5	0.8488	0.5	153

Ⅲ. 3차 모델 예측 결과

- B14 밴드 이미지 칩의 온도 대비로 3월 25일 산청-하동 17시 10분 화재 구역 예측
- (1) 예측 - 알지비 합성이 안되었고 과검출 되는 경향 존재 - 공격검출
- (2) 예측 -알지비 합성이 되었고 빨간 점을 잘 검출함.
- (3) 예측 - 붉은 점이 사라져 과소 검출됨- 보수 검출
- (4) 예측 - firms 구역과 항상 일치하지는 않음(3시간 이내 관측된 데이터)
- (5) 예측 - prediction 대비 노란 지점이 거리가 있어, 추후 더 작은 사이즈로 리사이즈 필요
- (6) 예측 - my model이 예측한 핫스팟 위치와 nasa firms 실제 화점이 상당히 겹쳐있음
- Precisioin=0.71은 대부분 예측이 실제 불 근처에서 발생하나 recall=0.26은 일부 화점 놓치고 있음



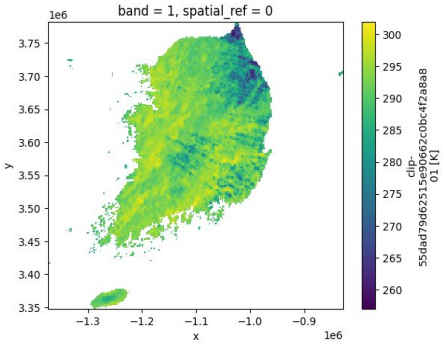

```
== Mean metrics by q ==
      q  precision  recall     F1
0  0.990      0.675   0.291  0.377
1  0.995      0.712   0.260  0.353
2  0.997      0.796   0.210  0.303
3  0.999      0.915   0.125  0.201
Best q by mean F1: 0.99
```



Ⅲ. 4차 모델 데이터셋

- 2025년 3.21~5.1 한국 지역(3곳 - 산청-하동, 안동-클러스터, 대구-경북)의 산불 데이터(이미지)
- 해당 지역 일자 최초 보고된 산불 발생 시점으로부터 2시간 이내 10분 간격으로 실시간 이미지를 수집
- himawari9 AHI 중 L1b 센서-FLDK (.DAT.bz2 형태), L2센서-NetCDF4형태)
- 밴드 B7 (3.9 μm, Shortwave IR) / B14 (11 μm, Thermal IR)
- 총 255장(GeoTIFF) 한국 영역 크롭 → 96x96로 타일링함
- 최종 데이터셋: 총 1,453개 이미지 칩, 타일 수 766(양성=535, 음성=231로 양성 비율 70%)

<전세계 - 한국 경계 크롭>



<이미지 칩 수>

```
=== per-split tile counts ===
train | pos=  498  neg=  384  total=  882
val   | pos=  267  neg=  298  total=  565
test  | pos=    5  neg=    1  total=    6

TOTAL  pos: 770 | neg: 683 | all: 1,453
```

<타일 수>

```
=== Split별 타일 수 ===
train | pos=  395  neg=  174  total=  569
val   | pos=  135  neg=   56  total=  191
test  | pos=    5  neg=    1  total=    6
```

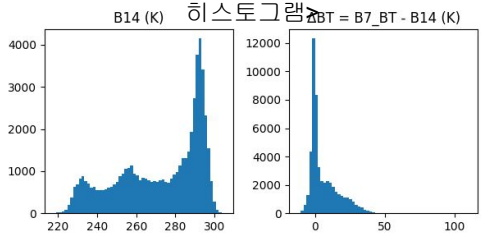
<지역 별 양성, 음성 타일 수>

```
=== tile stats ===
train | Daegu-Buk                | pos=  18, neg=  18
train | Sancheong-Hadong         | pos= 245, neg=  85
train | Uiseong-Andong-Cluster   | pos= 132, neg=  71
val   | Daegu-Buk                | pos=   8, neg=   8
val   | Sancheong-Hadong         | pos=  90, neg=  30
val   | Uiseong-Andong-Cluster   | pos=  37, neg=  18
test  | Daegu-Buk                | pos=   0, neg=   0
test  | Sancheong-Hadong         | pos=   5, neg=   1
test  | Uiseong-Andong-Cluster   | pos=   0, neg=   0
```

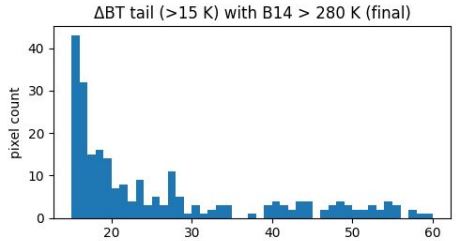
Ⅲ. 4차 모델 데이터셋 & 라벨링 (mask)

- Himawari-9 AHI 위성의 열적 적외 채널(B7: 3.9 μm, B14: 11 μm)fmf 이용하여 표면 온도 차(ΔBT = B7 − B14)를 계산
- 마스크 생성을 위해 ΔBT(B7–B14) ≥ 15 K 이상인 영역을 불 검출의 1차 임계값으로 설정함
- 총 최종 마스크는 보다 엄격한 수준의 핫스팟인 ΔBT > 15 K and B14 > 280 K 조건의 2차 임계값으로 설정
- 전체 픽셀 수: 23,805,952 px 중 전체 핫스팟 수: 13,701 px, 전체 비율 0.0576%
- “불균형 상황에서도 예측이 가능한가” (아주 작은 픽셀도 탐지하기 위한 목적)
- 구름 냉각 영역을 배제하고 실제 발열 지점을 안정적으로 검출하기 위한 2단계 임계값

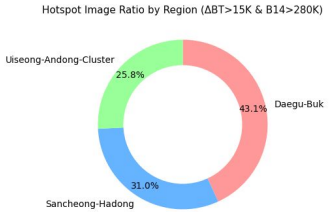
<정상온도 대 핫스팟 온도 히스토그램>



< 핫스팟의 열점별 히스토그램>



< 지역별 핫스팟의 분포>




```
=== Split별 픽셀 요약 ===
train | 총 픽셀: 14,450,688 | 핫스팟: 9,719 | 비율: 0.0673%
val   | 총 픽셀: 9,256,960 | 핫스팟: 3,506 | 비율: 0.0379%
test  | 총 픽셀: 98,304 | 핫스팟: 476 | 비율: 0.4842%
```

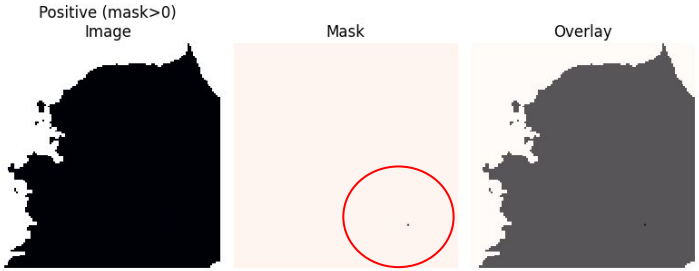
```
=== Region hotspot summary ===
Daegu-Buk           | imgs: 16  hot_imgs: 13 (81.25%)  hot_px_ratio:0.00%
Sancheong-Hadong    | imgs:130  hot_imgs: 76 (58.46%)  hot_px_ratio:0.03%
Uiseong-Andong-Cluster | imgs:109  hot_imgs: 53 (48.62%)  hot_px_ratio:0.01%
```

그래 설명: 히스토그램은 **B7, B14 채널의 온도 분포를 나타내며 **x**축은 복사온도, **y**축은 화소 수를 의미함.)*

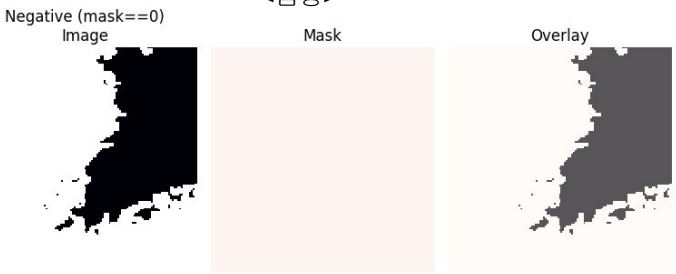
Ⅲ. 4차 모델 라벨링 (mask) 샘플 & 모델링

- 양성/음성 마스크 생성 결과
- 아주 작은 픽셀도 양성으로 포함(1점 이상 모두 양성)

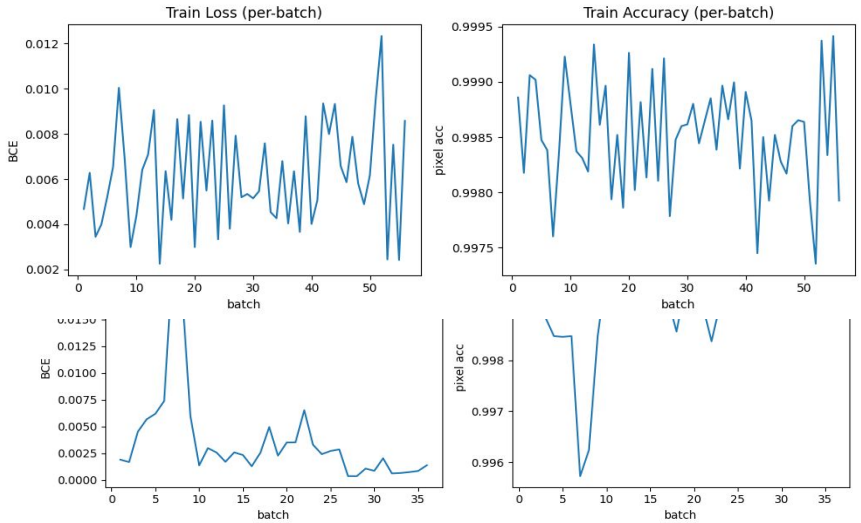
<양성>



<음성>



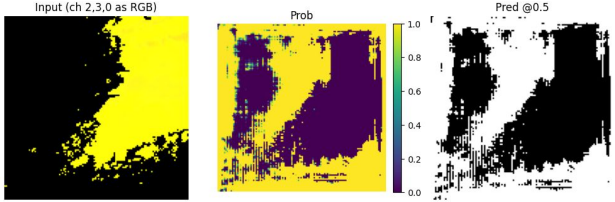
- 3차 모델에서 가장 성능이 좋았던 Unet restnet34 + force, dice를 사용하여 학습 및 훈련 진행
- [VAL] thr=0.75 (Recall≥0.9 -> R=0.905, P=0.371, F1=0.526)



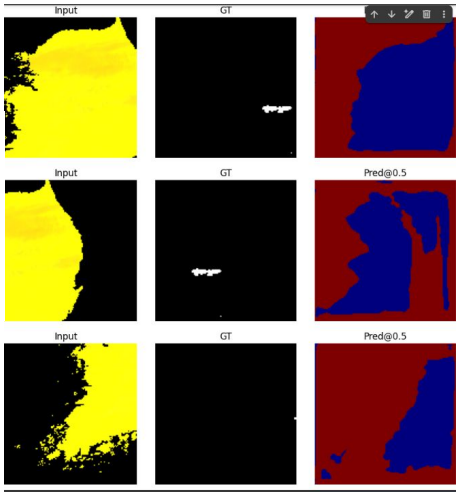
Ⅲ. 4차 모델링 예측 결과

- Pred 부분에서 검정색 부분이 한반도 부근이면 하얀 부분이 불 영역이며, 오른쪽은 모델이 불이라고 예측
- 검증 배치에서 양성이라고 판단한 영역이 많음
- 테스트 배치에서 성능이 낮아 양성 패치 오버샘플링과 freeze 등으로 불씨를 빨리 보도록 함에도 3차에 비해 낮은 성능능
- 결론: 산불 예측 데이터셋에는 지역의 다양성이 중요하며 3차 모델의 결과가 일반화가 잘 되는 경향

< 검증 배치>



< 테스트 배치>

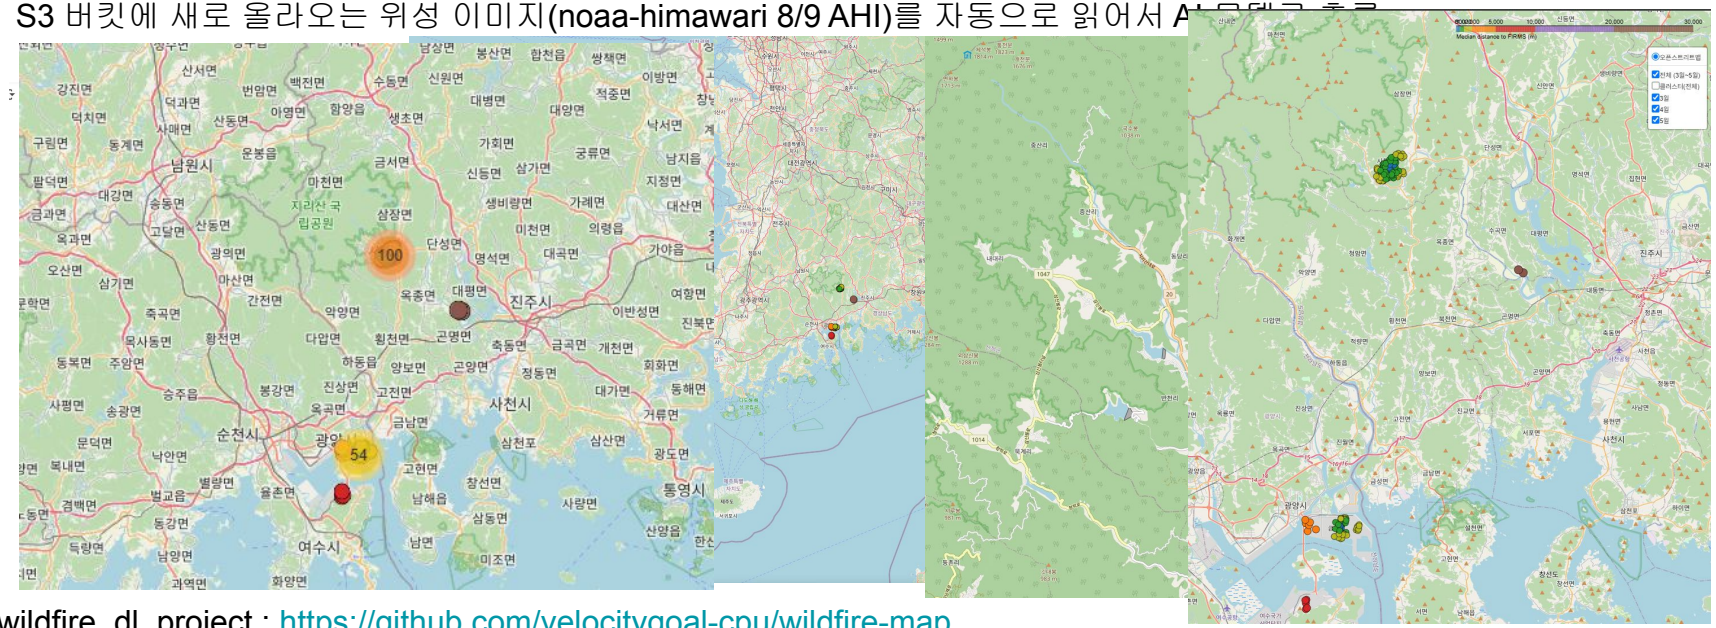


< score_rel_blur>

rank	x	y	s
1	8	9	0.49519020318984985
2	9	9	0.4678370952606201
3	8	8	0.45358943939208984
4	8	10	0.44344258308410645
5	9	8	0.43470609188079834
6	7	9	0.40966492891311646
7	9	10	0.40627509355545044
8	7	10	0.37729454040527344
9	7	8	0.3710622191429138
10	10	9	0.342843234539032

Ⅳ. 산불 예측 AI 시스템 구현

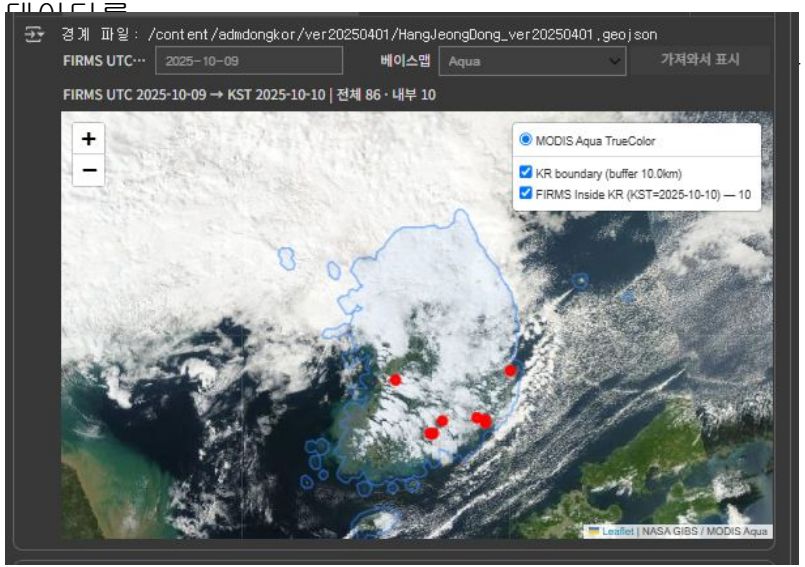
- 특정 지역, 특정 기간 화재 발생 건수 맵으로 표현하는 HTML 작성
- AWS EC2 가상환경에서 flask app으로 배포 . 점을 클릭시 모델의 F1, 재현율 확인 가능하며 클러스터로 수를 확인 가능함
- S3 버킷에 새로 올라오는 위성 이미지(noaa-himawari 8/9 AHI)를 자동으로 읽어서 AI 모델로 추론

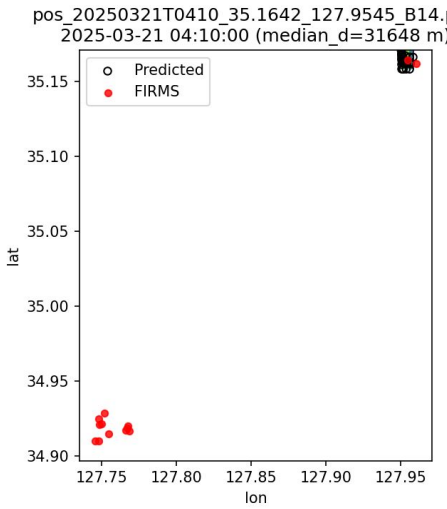


wildfire_dl_project : https://github.com/velocitygoal-cpu/wildfire-map

V. 결론 및 제언

- 실제 위성이미지에 실시간으로 화재 발생 예측 지점(다음 경로)을 표시하는 것
- 4차 모델 실험 결과, 온도의 차이로 학습되는 패턴보다 최대한 다양한 지역의 산불화재 과거 이력들을 수집하는 것이
- 모델의 성능을 향상시키는 데 주요한 요건이었으므로, 올해 2025년 3~5월의 데이터보다 지난 3년치 정도의 데이터를
- , 강 으로 보임





감사합니다.